

Experiment 4 - Modulare Upstream-Kopplung mit NN-PQ-Surrogat

Ziel und Forschungsfrage

Experiment 4 demonstriert die Modularitaet des differenzierbaren Power-Flow-Kerns. Die zentrale Frage lautet, ob derselbe stationaere AC-Power-Flow-Kern mit unterschiedlichen vorgelagerten Modellen gekoppelt werden kann, ohne die numerische Kernformulierung anzupassen.

Die Hypothese ist, dass analytische und neuronale Upstream-Modelle ueber eine einheitliche P/Q-Schnittstelle an `NetworkParams.p_spec_pu` und `NetworkParams.q_spec_pu` gekoppelt werden koennen, waehrend Konvergenz und Differenzierbarkeit erhalten bleiben.

Netz und Kopplungspunkt

Das Experiment verwendet `pandapower.networks.example_simple()` im scope-matched Modus. Der aktive `gen` wird wie in Experiment 1 bis 3 zu einem `sgen(P, Q=0)` vereinfacht. Das zu ersetzende Element ist weiterhin das `sgen` mit Name "`static generator`" am Bus "`MV Bus 2`".

Die Topologie bleibt statisch. Das ersetzte `sgen` wird bei der Netzbasis deaktiviert; alle Upstream-Modelle liefern P/Q-Injektionen in MW/MVAr, die ueber denselben Adapter `inject_pv_at_bus(...)` in das `NetworkParams`-Pytree geschrieben werden.

Vergleichene Upstream-Modelle

Das Referenzmodell `analytic_pv_weather` ist das bestehende analytische PV-Wettermodell aus Experiment 3. Es verwendet NOCT-SAM fuer die Zelltemperatur und die analytische PV-Leistungsformel.

Das Modell `nn_p_only_fixed_kappa` ist ein kleines JAX-MLP ohne Equinox, Flax, Optax oder andere ML-Dependencies. Es nutzt die Wetterinputs `g_poa_wm2`, `t_amb_c` und `wind_ms`, gibt eine normierte Wirkleistung aus und setzt $Q = -0.25 * P$. Damit bleibt das Q/P-Verhaeltnis des ersetzten `sgen "static generator"` erhalten.

Das Modell `direct_pq_scale_baseline` ist eine einfache differenzierbare Baseline mit $P = 2.0 * g_poa_wm2 / 1000.0$ und $Q = -0.25 * P$. Sie dient nur als weitere Schnittstellenkontrolle, nicht als fachlich genaues PV-Modell.

NN-Architektur und Training

Das Hauptmodell ist ein P-only-MLP mit drei Eingaben, zwei versteckten Schichten der Breite 8, `tanh`-Aktivierungen und einer skalaren Ausgabe. Die Default- Konfiguration des Hauptlaufs verwendet 8192 Trainingspunkte, 2048 Validierungspunkte und einen separaten 2048-Punkte-Evaluationssplit, einen festen Seed und einfaches Full-Batch-Gradient-Descent in JAX.

Kleine Smoke-Test-Konfigurationen in den Tests duerfen weiterhin deutlich weniger Punkte verwenden. Diese Mini-Konfigurationen pruefen nur Import, Trainingsmechanik und Exportschema; sie ersetzen nicht den dokumentierten Exp.-4-Hauptlauf.

Der synthetische Trainingsdatensatz wird durch Distillation des analytischen PV-Wettermodells erzeugt. Die Trainingsbereiche sind:

- `g_poa_wm2`: 0 bis 1200 W/m²,
- `t_amb_c`: -10 bis 45 degC,
- `wind_ms`: 0.5 bis 10 m/s.

Die Input-Normalisierung ist:

```
g_norm = (g_poa_wm2 - 600.0) / 600.0
t_norm = (t_amb_c - 17.5) / 27.5
w_norm = (wind_ms - 5.25) / 4.75
```

Die Zielgrösse fuer das Training ist `P_ref_mw / 2.0`.

Der grosse `eval`-Split dient der statistischen Surrogatfehler-Auswertung. Die kleine feste Liste repraesentativer Wetterfaelle bleibt separat erhalten und wird fuer Power-Flow-Modellvergleich, AD-vs-FD-Spotchecks und Sensitivitaetsmuster genutzt. Dadurch wird nicht versehentlich ein 2048-Punkte-Power-Flow-Vergleich ueber alle Modelle und Netzszenarien gestartet.

Bewertungsartefakte

Die Ergebnisse werden nach `experiments/results/exp04_modular_upstream_nn_surrogate/` geschrieben. Wesentliche Artefakte sind:

- `training_dataset_summary.csv/json`,
- `training_history.csv/json`,
- `surrogate_error_table.csv/json`,
- `model_comparison.csv/json`,
- `coupling_summary.csv/json`,
- `gradient_success_table.csv/json`,
- `sensitivity_pattern_summary.csv/json`,
- `run_summary.csv/json`,
- `metadata.json`,
- `README.md`.

`coupling_summary` dokumentiert direkt, dass alle Modelle denselben Kopplungsbus, denselben P/Q-Adapter, denselben Power-Flow-Kern und keine Controller-, Q-Limit- oder PV-PQ-Umschaltlogik verwenden.

`gradient_success_table` enthaelt repraesentative AD-vs-FD-Spotchecks fuer die Wetterinputs.

`sensitivity_pattern_summary` vergleicht lokale End-to-End-Sensitivitaetsmuster zwischen analytischem Modell, NN-Surrogat und direkter Baseline.

Bewusste Vereinfachungen

Das NN ist kein grosses Prognosemodell und wird nicht auf Messdaten trainiert. Es ist ein kleiner Distillation-Surrogatnachweis fuer die Kopplungsmodularitaet. Das Modell gibt nur Wirkleistung frei aus; Blindleistung

folgt deterministisch aus $\kappa = -0.25$. Es gibt keine Spannungsregelung, keine Q-Limits, keine PV-PQ-Umschaltung und keine Controllerlogik.

Die Aussage ist lokal und auf den dokumentierten Trainings- und Auswertungsbereich beschränkt. Die Ergebnisqualität des NN darf daher nicht als allgemeine PV-Prognosequalität interpretiert werden.